REPORTE TÉCNICO • PROYECTO APLICADO

Clasificación multiclase de pingüinos: datos, modelos y reproducibilidad

Actividad 5 | Palmer Penguins | Regresión logística vs. Random Forest

344	22	5	2
Registros originales	Configuraciones evaluadas	Folds estratificados	Modelos comparados

Propósito del proyecto

Preparar, auditar y versionar un conjunto de datos público; entrenar y ajustar dos algoritmos con validación cruzada; evaluar sobre un test reservado; documentar resultados, incertidumbre y deuda técnica; e implementar el registro de experimentos mediante MLflow.

ESTADO DE VALIDACIÓN

Se ejecutaron los pipelines, Grid Search, pruebas unitarias y gráficas en un entorno offline. **El registro MLflow no fue ejecutado aquí** por no disponer de la librería ni acceso para instalarla. El repositorio Git está preparado localmente, pero no ha sido publicado en una cuenta de GitHub. No se incluyen capturas ficticias.

Versión 1.0 · 18 de octubre de 2026 · Proyecto reproducible con archivos adjuntos

1. Resumen ejecutivo y hallazgos

El proyecto utiliza 344 registros de las especies Adelie, Chinstrap y Gentoo. Los datos se mantuvieron completos en número de filas tras su depuración; los valores faltantes de variables predictoras se resuelven **exclusivamente dentro del pipeline** para prevenir fuga de información.

La regresión logística consiguió F1 macro de **1.0000** en 69 observaciones de test, frente a **0.9829** de Random Forest. En validación cruzada, las medias de F1 macro fueron 0.9970 y 0.9786, respectivamente. Las diferencias favorecen a la regresión logística en este conjunto, aunque el tamaño y origen de la muestra limitan la extrapolación.

Diseño para evitar sobreajuste y filtración

- **Separación:** 275 registros en entrenamiento y 69 en test, estratificados por especie y con semilla 42.
- **Selección:** GridSearchCV con 5 pliegues estratificados dentro de entrenamiento; el test no interviene en la búsqueda.
- **Transformación:** imputación y codificación dentro de ColumnTransformer/Pipeline; normalización numérica solo para regresión logística.
- **Comparación:** métricas homogéneas y bootstrap pareado con 2,000 remuestreos de los mismos casos de prueba.

2. Datos: origen, variables y supuestos

El conjunto público **Palmer Penguins** proviene del proyecto palmerpenguins, desarrollado para facilitar el aprendizaje de análisis de datos con observaciones de pingüinos en el entorno de Palmer Station, Antártida (años 2007 a 2009). La copia CSV utilizada está incluida en el ZIP y procede de la distribución local de plotnine; su estructura coincide con el archivo público documentado en GitHub.

Diccionario de datos

Campo	Tipo	Uso y definición
species	Categórica	Variable objetivo: Adelie, Chinstrap o Gentoo.
island	Categórica	Isla de muestreo (Biscoe, Dream, Torgersen).
bill_length_mm	Numérica	Longitud del pico (mm).
bill_depth_mm	Numérica	Profundidad del pico (mm).
flipper_length_mm	Numérica	Longitud de aleta (mm).
body_mass_g	Numérica	Masa corporal (g).
sex	Categórica	Sexo registrado o nulo.
year	Entero	Año del registro (se conserva, no se usa como predictor).

Supuestos: registros individuales de observación; mediciones corporales cuantitativas en sus unidades originales; no se asume representatividad fuera de las islas y años muestreados. `year` se excluye como predictor por su posible efecto espurio de campaña; `island` se conserva, pero se reconoce el riesgo de dependencia geográfica.

3. Preparación, calidad y versionamiento

El archivo original se conserva sin edición. El script **fuentes/datos_prep.py** comprueba el esquema, limpia cadenas y tokens de faltantes, convierte numéricos, marca mediciones no positivas como nulas, valida el rango 2007-2009, elimina filas sin etiqueta y retira duplicados exactos. El resultado se guarda en CSV con un archivo de auditoría JSON que contiene conteos y huellas SHA-256.

Resultado de auditoría de calidad

Control	Observación en la copia original
Registros antes/después	344 / 344
Duplicados exactos eliminados	0 (la regla se implementa y prueba)
Etiquetas objetivo sin valor	0
Ausentes en medidas numéricas	2 por cada variable numérica
Ausentes en sexo	11
Ausentes en isla / año / especie	0 / 0 / 0
Invalidados por valor físicamente imposible	0 en las medidas numéricas originales

Limpieza vs. transformación estadística

Se mantienen los nulos de los predictores en **datos_limp/penguins_limpios.csv** a propósito. La mediana de cada columna numérica, la moda de cada variable categórica y las escalas se aprenden **solo del fold de entrenamiento** correspondiente. Las variables `island` y `sex` se codifican con OneHotEncoder; las categorías nuevas se ignoran sin error. Este orden impide que estadísticas del test influyan en entrenamiento.

Estrategia de trazabilidad

SHA-256 original: `1867a776a83379df4219f227bb1effb967da12adb13732127c8c8d120434c29b`

SHA-256 limpio: `9054e0bf9ac999173106073b31e4cbce12513642e911719f6b9a5dffce17638b`

Se usan Git y CHANGELOG.md para registrar versiones y decisiones. La auditoría enlaza los dos ficheros mediante sus hashes; en una corrida MLflow real el script registra ambos SHA-256 como etiquetas. El ZIP incluye historial Git local; su publicación remota en GitHub está pendiente de permisos.

4. Exploración: patrones, faltantes y anomalías

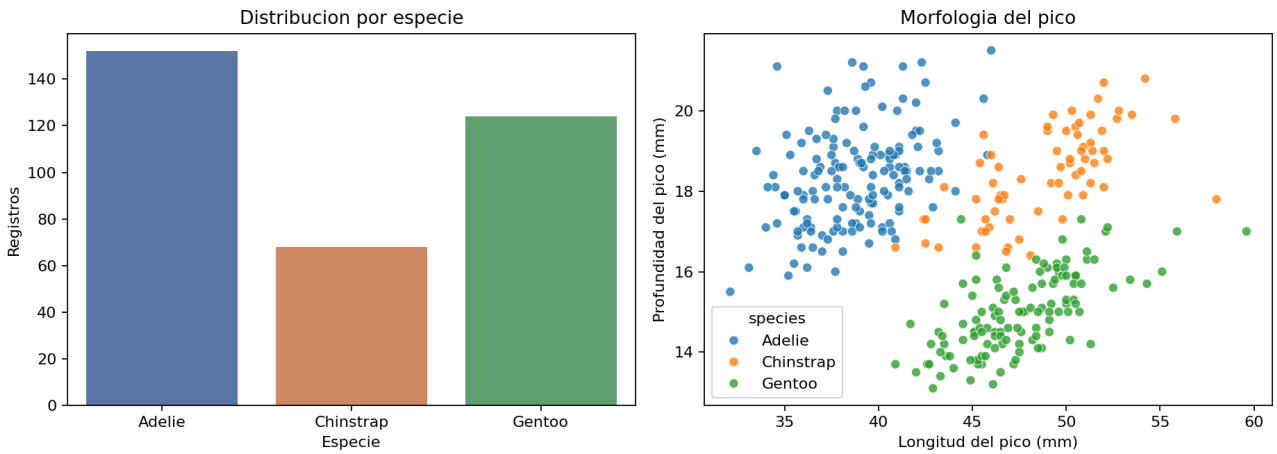


Figura 1. Adelie (152 registros), Gentoo (124) y Chinstrap (68): existe desbalance moderado. La longitud y profundidad del pico muestran regiones separables, aunque solapamientos entre especies; favorece comparar un límite de decisión lineal con un conjunto de árboles.

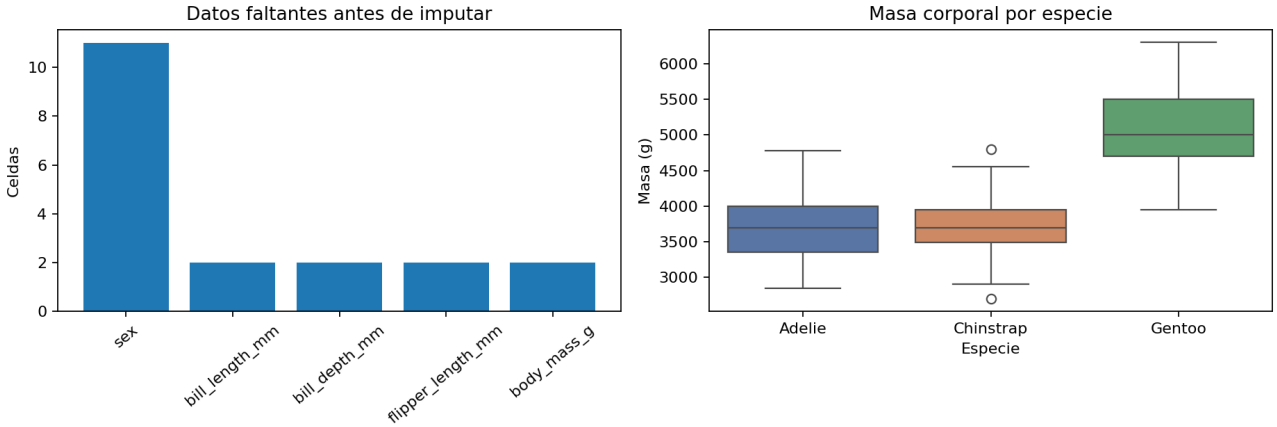


Figura 2. Sexo contiene 11 nulos y cada medida física, 2; por ello es pertinente una imputación aprendida en cada fold. La masa corporal difiere entre especies; se evitan reglas de eliminación de valores atípicos sin evidencia biológica. El criterio exploratorio 1.5 × IQR no marcó valores extremos por ninguna medida.

5. Modelos, hiperparámetros y evaluación

La regresión logística se usa como línea base interpretable y regularizada; se estandarizan sus variables numéricas para evitar dependencia de la escala. Random Forest modela interacciones y relaciones no lineales y no necesita reescalado numérico. Ambos comparten tratamiento de nulos/categorías y la misma partición, semilla y pliegues.

Modelo	Hiperparámetros de Grid Search	Justificación
Regresión logística	C = 0.1, 1, 10; class_weight = None, balanced (6 candidatos).	Regularización y compensación potencial del desbalance.
Random Forest	n_estimators = 100, 200; max_depth = None, 6; min_samples_leaf = 1, 3; class_weight = None, balanced (16 candidatos).	Estabilidad del ensemble, control de complejidad y peso de clases.

El criterio de selección es **F1 macro** (promedio no ponderado de F1 por especie), que da visibilidad a la clase con menos registros. En test se calculan accuracy, precision macro, recall macro, F1 macro y ROC-AUC

multiclase One-vs-Rest (macro). Para ROC-AUC se usan las probabilidades del modelo, no las etiquetas duras.

Hiperparámetros seleccionados por CV

Modelo	Configuración ganadora
Regresión logística	C = 10; class_weight = None; max_iter = 3000.
Random Forest	n_estimators = 100; max_depth = None; min_samples_leaf = 1; class_weight = None.

6. Resultados cuantitativos

Métrica	Regresión logística	Random Forest
F1 macro CV, media ± desv. est.	0.9970 ± 0.0060	0.9786 ± 0.0191
Accuracy test	1.0000	0.9855
Precision macro test	1.0000	0.9778
Recall macro test	1.0000	0.9889
F1 macro test	1.0000	0.9829
ROC-AUC OvR macro test	1.0000	1.0000

Valores calculados sobre 69 registros de prueba independientes del Grid Search. Las desviaciones CV describen dispersión entre folds; no son intervalos de confianza ni tests de hipótesis.

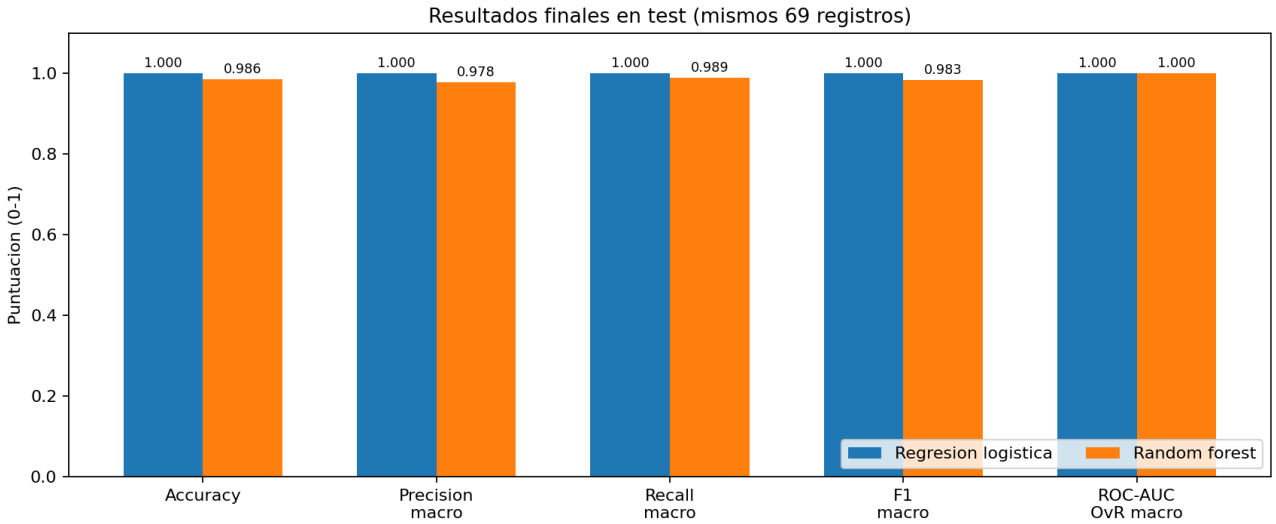


Figura 3. Comparación en las mismas instancias de test: la regresión logística supera ligeramente al bosque en F1 macro. ROC-AUC = 1.000 en ambos modelos expresa separación probabilística observada, no identidad de predicciones por clase.

7. Interpretación visual y análisis estadístico

Errores sobre test independiente

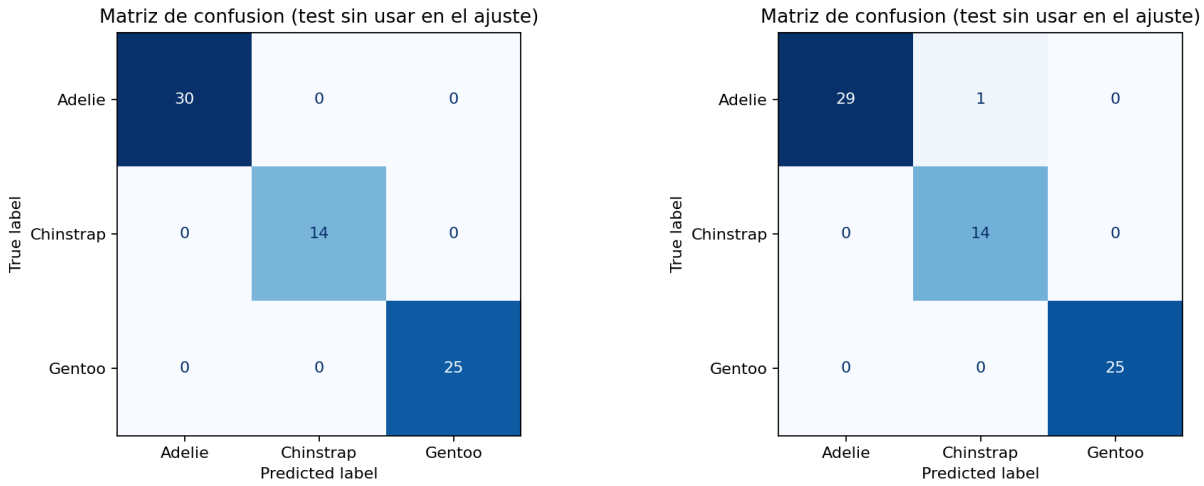


Figura 4. Izquierda: regresión logística; derecha: Random Forest. La matriz de confusión hace visible que un score agregado casi perfecto puede ocultar errores aislados, especialmente relevantes cuando las clases son de diferente tamaño.

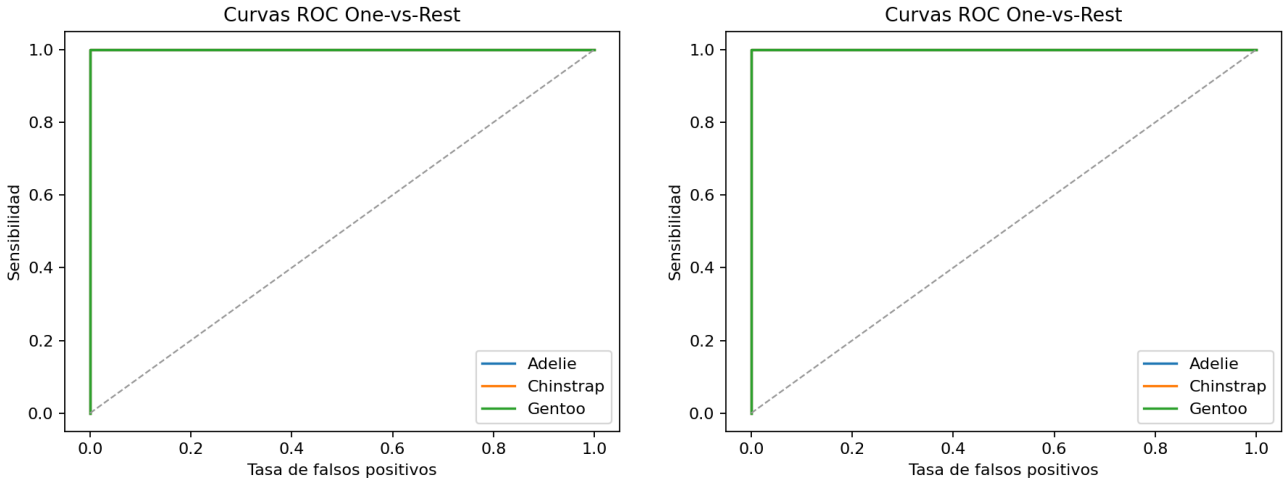


Figura 5. Curvas ROC One-vs-Rest para las tres especies. No se pueden inferir probabilidades calibradas solo a partir de esta métrica; calibración y validación fuera de muestra quedan pendientes.

Bootstrap pareado sobre F1 macro

Diferencia definida como **F1(Random Forest) - F1(regresión logística)**: **-0.0171**. Con 2,000 remuestreos estratificados de los 69 casos de test (mismos índices para ambos modelos), el intervalo percentil 95 % fue **[-0.0498, 0.0000]**. La diferencia observada es pequeña y el extremo superior incluye 0; no se afirma superioridad estadística generalizable.

Limitaciones metodológicas: conjunto pequeño, observaciones del mismo ecosistema y distribuciones de isla/especie potencialmente correlacionadas. Para comparar rendimiento real fuera de distribución se necesitarían conjuntos externos o particiones por campañas geográficas/temporales, además de repetición con distintas semillas.

8. Registro en MLflow: implementación y estado real

Implementación disponible: `fuentes/train.py` define un experimento local con nombre explícito, una corrida final por modelo, 6 + 16 corridas hijas para cada candidato de Grid Search y una corrida comparativa. Registra hiperparámetros, métricas CV/test, huellas de los CSV, gráficos, audit JSON y el pipeline completo (preprocesado y estimador) con firma y ejemplo.

Validación efectivamente realizada: el modo `--sin-mlflow` verificó el entrenamiento y los artefactos en disco. **MLflow no se ejecutó** porque no estaba instalado y no había conectividad disponible para obtenerlo. No existen capturas auténticas del panel ni identificadores de corridas MLflow correspondientes a esta ejecución. El campo `tracking_mlflow_ejecutado` del JSON es `false`.

Procedimiento de evidencia para completar al reproducir

- Instalar `requirements.txt`, ejecutar `python fuentes/train.py` sin la bandera offline y abrir la UI mediante `mlflow ui --backend-store-uri ./mlruns --port 5000`.
- Capturar la lista del experimento con métricas, el detalle de parámetros/métricas, y la sección de artefactos/modelo. Guardar las imágenes reales bajo `evidencias_mlflow/capturas/`.
- Verificar hashes de origen y limpieza en las etiquetas de cada run; conservar el historial Git y, cuando haga falta, exportar el FileStore de tracking a almacenamiento persistente.

Esta distinción entre **código implementado** y **evidencia verificada** es indispensable para no sobreestimar la trazabilidad entregada.

9. Deuda técnica y plan de mejora MLOps

Riesgo identificado	Impacto	Acción recomendada
Dependencias con rangos amplios	Variación en futuras instalaciones.	Publicar lockfile/imagen Docker con versiones exactas y verificación CI.
Tracking local de archivos	Pérdida de corridas al borrar sesión.	Backend y almacén de artefactos persistentes con controles de acceso.
Muestra y dominio limitados	Optimismo, drift geográfico o temporal.	Evaluación externa por isla/año y vigilancia de datos y desempeño.
Ausencia de aprobación para despliegue	Riesgo de modelo sin revisión.	Model Registry, etapas, auditoría, criterios de promoción y rollback.
Calidad de entrada variable	Errores por nuevas categorías o sensores.	Checks de esquema/rangos, tests de inferencia, alertas y monitoreo.

10. Conclusiones y referencias

La preparación reproducible, la validación estratificada y el holdout sustentan una comparación consistente de dos enfoques. Para este dataset, la regresión logística es la opción preferible como línea base por su simplicidad y resultado observado; la diferencia es pequeña y no respalda una afirmación universal. La siguiente etapa necesaria para cierre completo de la rúbrica es ejecutar el tracking real y publicar el repositorio en una cuenta con autorización.

Referencias: Horst et al., palmerpenguins (https://github.com/allisonhorst/palmerpenguins); scikit-learn, GridSearchCV (https://scikit-learn.org); MLflow, Tracking (https://mlflow.org/docs/latest/ml/tracking/).